

Projet de bioinformatique

Déployer et comprendre AlphaFold2

1 Contexte et objectif

AlphaFold2 permet de prédire la structure tridimensionnelle d'une protéine à partir de sa séquence.

L'objectif de ce projet n'est pas uniquement d'utiliser AlphaFold2 une fois, mais de comprendre **comment mettre en place un environnement permettant de l'utiliser**, comment effectuer une prédiction et comment interpréter les principaux résultats obtenus.

Votre mission est la suivante :

Mettre en place et documenter une solution permettant d'utiliser AlphaFold2, de telle manière qu'un étudiant de la promotion suivante puisse reprendre votre travail et effectuer une nouvelle prédiction sans devoir recommencer vos recherches et vos essais.

Votre travail devra donc répondre à trois questions principales :

1. Comment fonctionne AlphaFold2 dans les grandes lignes ?
2. Comment peut-on concrètement l'utiliser ?
3. Comment interpréter les résultats qu'il produit ?

Une attention particulière sera portée à la **démarche technique et à sa documentation**.

2 Votre mission

Vous devez mettre en place un workflow fonctionnel permettant de réaliser le processus suivant :

séquence protéique → AlphaFold2 → structure prédite → analyse des résultats

Vous êtes libres de déterminer la solution technique que vous jugez appropriée.

Cette liberté fait partie du projet.

Vous devrez rechercher les différentes possibilités existantes, en sélectionner une et être capables de justifier votre choix.

L'objectif n'est pas nécessairement de réaliser l'installation la plus complexe. Une solution simple est parfaitement acceptable si vous pouvez expliquer pourquoi elle est adaptée.

3 Comprendre le problème avant de commencer

Avant de choisir votre solution technique, renseignez-vous sur AlphaFold2.

Vous devez être capables d'expliquer avec vos propres mots :

- quelle est l'entrée d'AlphaFold2 ;
- quelle est la sortie recherchée ;
- ce qu'est un alignement multiple de séquences (MSA) ;
- pourquoi des séquences homologues peuvent apporter de l'information sur la structure d'une protéine ;
- quelles sont les grandes étapes permettant de passer d'une séquence à une structure prédite ;
- pourquoi AlphaFold2 produit également des mesures de confiance.

Il n'est **pas demandé** de maîtriser les détails mathématiques du réseau neuronal ni de décrire en détail son architecture.

Votre objectif est de comprendre suffisamment le système pour pouvoir expliquer quelles informations entrent dans AlphaFold2, comment elles sont exploitées dans les grandes lignes et ce qui en ressort.

Production demandée

Réalisez **votre propre schéma** expliquant le fonctionnement général d'AlphaFold2.

Votre schéma doit permettre à un étudiant en bioinformatique qui ne connaît pas AlphaFold2 d'en comprendre le principe général.

4 Étude des solutions techniques

Recherchez comment il est actuellement possible d'effectuer une prédiction avec AlphaFold2.

Avant de vous lancer dans l'installation ou l'utilisation d'une solution, comparez brièvement les possibilités que vous avez trouvées.

Pour chaque solution sérieusement envisagée, déterminez si possible :

- ce qu'il faut installer ;
- où le calcul est réalisé ;
- les ressources informatiques nécessaires ;
- les bases de données éventuellement nécessaires ;
- les avantages de la solution ;
- ses inconvénients ;
- ses limitations éventuelles.

Vous ne devez pas tester toutes les solutions.

L'objectif est de démontrer que votre choix technique résulte d'une démarche raisonnée.

Production demandée

Présentez brièvement les solutions envisagées et expliquez :

Quelle solution avez-vous retenue et pourquoi ?

5 Mise en place de votre solution

Mettez en place la solution choisie.

Cette partie constitue une composante importante du projet.

Documentez **ce que vous faites au fur et à mesure**.

Votre documentation devra notamment préciser, lorsque cela est pertinent :

- le système ou environnement utilisé ;
- les logiciels installés ;
- les versions ;
- les bibliothèques ou dépendances ;
- les commandes exécutées ;
- les fichiers de configuration créés ;
- les éventuels comptes ou services externes nécessaires ;
- les ressources matérielles utilisées ;
- les difficultés rencontrées ;
- les solutions trouvées.

Ne vous contentez pas d'écrire :

« Nous avons installé AlphaFold2. »

L'objectif est de permettre à quelqu'un d'autre de comprendre **comment** vous êtes arrivés à une solution fonctionnelle.

6 Produire une procédure réutilisable

Imaginez que votre travail soit transmis tel quel aux étudiants de l'année prochaine.

Ils doivent pouvoir commencer par votre documentation et arriver à une prédiction sans refaire tout votre travail d'exploration.

Vous devez donc produire un document `README.md` constituant le **mode d'emploi de votre solution**.

Il devra au minimum contenir les éléments suivants.

Prérequis

De quoi faut-il disposer avant de commencer ?

Installation ou préparation

Que faut-il installer ou configurer ?

Dans quel ordre ?

Exécution

Comment soumettre une nouvelle séquence ?

Quelles commandes ou opérations faut-il réaliser ?

Résultats

Où apparaissent les résultats ?

Quels fichiers sont importants ?

Problèmes connus

Quelles difficultés avez-vous rencontrées ?

Comment les avez-vous résolues ?

Limites

Dans quelles circonstances votre solution pourrait-elle ne plus fonctionner ou ne pas être adaptée ?

7 Tester votre procédure sur une protéine réelle

Choisissez une protéine réelle de taille raisonnable.

Pour ce projet, une protéine comportant **environ 100 à 400 résidus** constitue un bon ordre de grandeur.

Cette plage n'est pas une contrainte absolue, mais une recommandation destinée à conserver des temps de calcul raisonnables tout en travaillant sur une protéine suffisamment grande pour obtenir des résultats intéressants.

Si vous choisissez une protéine nettement plus courte ou plus longue, justifiez brièvement ce choix et vérifiez que celui-ci reste compatible avec le temps et les ressources disponibles pour le projet.

Documentez :

- son nom ;
- l'organisme ;

- l'identifiant de la séquence ;
- la base de données utilisée ;
- sa longueur ;
- la séquence effectivement utilisée.

Expliquez brièvement votre choix.

Utilisez ensuite votre workflow pour obtenir une prédiction.

Conservez les résultats nécessaires à l'analyse.

8 Démontrer que votre workflow fonctionne

Votre projet ne peut pas se limiter à une procédure d'installation.

Vous devez démontrer que celle-ci permet effectivement d'obtenir et d'exploiter une prédiction.

Présentez la structure tridimensionnelle obtenue et identifiez les principaux fichiers ou résultats produits par votre solution.

Expliquez notamment :

- où se trouve la structure prédite ;
- dans quel format elle est disponible ;
- quelles informations de confiance sont fournies ;
- quels autres fichiers vous semblent importants.

L'objectif n'est pas de décrire exhaustivement tous les fichiers produits, mais de permettre au prochain utilisateur de savoir **où regarder et ce qu'il trouvera**.

9 Analyser le pLDDT

Recherchez ce que représente le **pLDDT**.

Expliquez avec vos propres mots :

- ce qu'il mesure ;
- ce qu'une valeur élevée signifie ;
- ce qu'une valeur faible signifie ;
- comment cette information doit être utilisée.

Vous devez ensuite retrouver ces valeurs dans les résultats de **votre propre prédiction**. Décrivez comment vous avez accès à ces informations.

Décrivez brièvement vos résultats. L'objectif n'est pas d'effectuer une étude biologique approfondie

de la protéine, mais de démontrer que vous savez **extraire, manipuler et interpréter les résultats produits par votre workflow**.

10 Examiner la PAE

Déterminez ce que représente la **Predicted Aligned Error (PAE)** et en quoi elle diffère du pLDDT.

Retrouvez la PAE dans les résultats produits par votre solution. Décrivez comment vous pouvez avoir accès à ces informations.

Présentez la matrice correspondante.

Expliquez brièvement :

- ce que représentent les deux axes ;
- ce que signifient les valeurs ;
- ce que cette information apporte par rapport au pLDDT.

Il n'est pas demandé d'effectuer une analyse structurale approfondie de la PAE.

11 Ce que vous transmettez à la promotion suivante

À la fin du projet, posez-vous la question suivante :

Si un étudiant reçoit notre travail l'année prochaine avec une nouvelle séquence, peut-il obtenir une prédiction sans refaire toutes nos recherches ?

Créez dans votre README une section intitulée :

Pour les étudiants de l'année prochaine

Elle doit présenter, de manière très concise :

1. ce qu'il faut installer ou ouvrir ;
2. comment préparer une séquence ;
3. comment lancer la prédiction ;
4. combien de temps approximativement il faut prévoir ;
5. où récupérer les résultats ;
6. comment lancer votre analyse pLDDT ;
7. comment afficher et interpréter la PAE ;
8. les principaux pièges à éviter.

Cette section doit constituer un **mode d'emploi directement utilisable**, et non le récit de ce que vous avez fait.

12 Rapport

Remettez un rapport de **taille raisonnable**.

À titre indicatif, un rapport de l'ordre de **5 à 6 pages** constitue un ordre de grandeur approprié pour ce projet. Les annexes, références bibliographiques et autres éléments complémentaires ne sont pas compris dans cet ordre de grandeur.

Il ne s'agit pas d'une limite stricte : la longueur du rapport doit avant tout être adaptée au contenu et rester proportionnée au travail demandé.

Le rapport doit rester synthétique et présenter les éléments suivants :

1. AlphaFold2

Principe général et schéma explicatif.

2. Choix technique

Solutions envisagées et justification de celle retenue.

3. Mise en œuvre

Environnement, installation ou configuration et difficultés rencontrées.

4. Test

Protéine utilisée et résultat obtenu.

5. Analyse

pLDDT et PAE.

6. Retour d'expérience

Ce qui a fonctionné, ce qui a posé problème et ce que vous recommandez aux prochains utilisateurs.

Les instructions techniques détaillées doivent se trouver dans le `README.md`, plutôt que d'alourdir inutilement le rapport.

13 Sources et traçabilité

Les informations techniques et scientifiques importantes doivent être accompagnées de leurs sources.

Privilégiez :

- les publications scientifiques ;
- les documentations officielles ;
- les dépôts officiels des logiciels ;
- les bases de données biologiques reconnues.

Conservez également les liens vers les documentations ou ressources techniques qui vous ont réellement aidés à résoudre le projet.

Le but n'est pas d'accumuler une bibliographie importante, mais de permettre de retrouver **d'où viennent les informations et les solutions utilisées**.

14 Utilisation d'intelligences artificielles génératives

L'utilisation d'outils d'intelligence artificielle générative est entièrement **autorisée** dans le cadre de ce projet.

Vous pouvez notamment les utiliser pour :

- comprendre une notion ;
- rechercher des pistes ;
- obtenir de l'aide lors d'une installation ;
- comprendre un message d'erreur ;
- écrire ou corriger du code ;
- améliorer une explication ;
- interpréter un format de fichier ;
- résoudre un problème technique.

L'utilisation d'une IA doit cependant être **traçable**, de la même manière que l'utilisation d'une autre source.

Lorsqu'un échange avec une IA a contribué de manière significative à une partie de votre travail, vous devez fournir **le lien public permettant de consulter la conversation correspondante**.

Dans votre rapport, votre README ou votre code, indiquez l'utilisation de l'IA à l'endroit concerné.

Par exemple :

« Le script d'extraction du pLDDT a été développé avec l'aide de Claude [lien vers la conversation]. »

ou :

« Nous avons utilisé ChatGPT pour comprendre l'origine de cette erreur d'installation [lien vers la conversation]. »

Il n'est pas nécessaire de référencer chaque correction orthographique ou chaque question mineure.

En revanche, si une conversation a contribué à :

- un choix technique ;
- une installation ;
- une portion significative de code ;
- la résolution d'un problème ;
- une explication scientifique ;
- l'interprétation d'un résultat ;

le lien vers cette conversation doit être fourni.

Un lien vers la page d'accueil de l'outil d'IA n'est pas suffisant : il faut partager **le lien public vers l'échange concerné**.

L'utilisation d'une IA n'est pas considérée comme un problème ou comme une diminution de la qualité du travail. Vous êtes au contraire invités à utiliser les outils qui vous permettent de travailler efficacement.

Vous restez cependant responsables de ce que vous remettez.

Vous devez donc être capables de comprendre, vérifier et expliquer les informations, le code et les solutions obtenus avec l'aide d'une IA.

15 Ce qui n'est pas demandé

Compte tenu du temps disponible, il ne vous est **pas demandé** :

- de comprendre les détails mathématiques du réseau neuronal ;
- de réimplémenter AlphaFold2 ;
- d'entraîner un modèle ;
- d'effectuer une étude biologique approfondie ;
- de comparer systématiquement la prédiction à des structures expérimentales ;
- d'étudier des mutations ;
- de réaliser une analyse statistique sur de nombreuses protéines.

Concentrez votre travail sur :

comprendre → mettre en place → documenter → tester → analyser les principales sorties

16 Livrables

À la fin du projet, vous devez remettre :

- le **rapport** ;
- le **README**, constituant la documentation technique réutilisable ;
- le **code** utilisé pour analyser les résultats ;
- la **séquence** utilisée pour tester votre workflow ;
- les **résultats et figures** nécessaires pour comprendre et vérifier votre travail ;
- les **références scientifiques et techniques** utilisées ;
- les **liens publics vers les conversations avec des IA génératives** ayant contribué de manière significative au projet.

Le résultat final doit permettre à une autre personne de comprendre non seulement **ce que vous avez obtenu**, mais surtout **comment vous l'avez obtenu et comment elle pourrait le refaire**.